UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO
CENTRO MULTIDISCIPLINAR DE PAU DOS FERROS
ENGENHARIA DA COMPUTAÇÃO
PROFESSOR DR. PEDRO THIAGO VALÉRIO DE SOUZA
SISTEMAS INTELIGENTES

THIAGO GEOVANE DA COSTA NUNES

PROJETO 1: MODELO DE REGRESSÃO LINEAR

PAU DOS FERROS – RN
2026

Sumário

1.INTRODUÇÃO.....3

2. METODOLOGIA.....3

3. RESULTADOS E DISCUSSÕES.....4

4. CONCLUSÃO.....6

ANEXO I.....7

1.INTRODUÇÃO

O presente trabalho tem como objetivo investigar como as variáveis de uma usina termoelétrica se relacionam juntamente com a produção de energia elétrica, utilizando técnicas de análise estatística e regressão linear múltipla.

As variáveis utilizadas foram:

- AT (Ambient Temperature): Temperatura em °C. Afeta a densidade do ar e a eficiência da combustão
- V (Exhaust Vacuum): Vácuo de escape em cm Hg. Relacionado à pressão na turbina a vapor.
- AP (Ambient Pressure): Pressão atmosférica em mbar.
- RH (Relative Humidity): Umidade relativa em percentagem.
- PE (Net Hourly Electrical Energy Output): A variável alvo em MW (MegaWatts).

2. METODOLOGIA

Para treino do modelo foi utilizado o utilizamos o dataset UCI CCPP (disponível em https://archive.ics.uci.edu/ml/datasets/Combined+Cycle+Power+Plant). O dataset contém 9.568 amostras coletadas ao longo de 6 anos

Inicialmente, foi conduzida uma análise exploratória dos dados com o objetivo de compreender a distribuição das variáveis, identificar possíveis valores discrepantes (*outliers*) e avaliar o grau de associação linear entre os atributos por meio do coeficiente de correlação de Pearson.

Na etapa seguinte, o conjunto de dados foi particionado aleatoriamente em dois subconjuntos: 80% destinados ao treinamento do modelo e 20% reservados para teste, garantindo que a avaliação de desempenho fosse realizada sobre dados não vistos durante o ajuste.

O modelo adotado foi a regressão linear múltipla, no qual as variáveis AT, V, AP e RH atuam como preditoras da variável-alvo PE. Essa técnica foi escolhida por sua interpretabilidade e adequação a problemas em que se busca quantificar a contribuição individual de cada fator sobre a variável de resposta.

3. RESULTADOS E DISCUSSÕES

No presente tópico segue a análise dos dados e respostas das questões pedidas pelo docente.

Tabela 1 – Correlação com PE

Variáveis	Correlação
AP	0.518429
RH	0.389794
V	-0.869780
AT	-0.948128

1. Calcule a correlação entre as variáveis independentes (AT, V, AP, RH) e a variável dependente (PE). Quais variáveis parecem ter maior influência na produção de energia?

Como apontado na **tabela 1** há uma forte correlação negativa entre AT com PE, ou seja que elas tem uma correlação inversa, quando uma aumenta outra diminui. já V tem algo próximo mas não chega a ser uma forte correlação a mesma seria inversa também, ambas quanto maiores menor a eficiência da usina.

Já as duas outras variáveis independentes tem baixa correlação e ainda assim positivas que se elas aumentam não interferem muito na eficiência da usina, apesar de serem positivas tem valores baixos de correlação.

2. Calcule a correlação entre as variáveis independentes (AT, V, AP, RH) entre si. Existe alguma relação forte entre elas? Se sim, isso pode indicar multicolinearidade.

Tabela 2 – Correlação das variáveis independentes

	AT	V	AP	RH
AT	1.000000	0.844107	-0.507549	-0.542535
V	0.844107	1.000000	-0.413502	-0.312187
AP	-0.507549	-0.413502	1.000000	0.099574
RH	-0.542535	-0.312187	0.099574	1.000000

Como fica denotado na **tabela 2** as variáveis que tem uma correlação considerável seriam apenas V e AT, com um valor de correlação de 0.844107, além de que é positiva o que indica que elas são proporcionais, ou seja, quando uma aumenta a outra aumenta, o que explicaria elas terem correlações inversas parecidas com Pel.

3. Construa um modelo de regressão linear múltipla utilizando as variáveis independentes (AT, V, AP, RH) para prever a variável dependente (PE). Divida os dados em treino (80%) e teste (20%).

Foi construído um modelo de regressão linear múltipla com o objetivo de prever a produção de energia (PE) a partir das variáveis independentes AT, V, AP e RH. Os dados foram divididos em dois conjuntos: 80% para treinamento e 20% para teste, permitindo avaliar a capacidade de generalização do modelo. O modelo foi treinado utilizando o conjunto de treinamento e posteriormente utilizado para realizar previsões no conjunto de teste.

4. Avalie o desempenho do modelo utilizando métricas como R^2, RMSE e MAE. O modelo é adequado para prever a produção de energia? Justifique sua resposta.

Tabela 3 – valores de métricas

R^2	0.9301046431962188
RMSE	4.502633229532186
MAE	3.595913178273408

O desempenho do modelo de regressão linear múltipla foi avaliado sobre o conjunto de teste por meio das métricas presentes na **tabela 4.**

O coeficiente de determinação obtido R^2 indica que o modelo é capaz de acertar em 93% da predição dos valores. Esse resultado evidencia um ajuste expressivo, especialmente considerando a natureza contínua e multifatorial do fenômeno modelado.

O erro quadrático médio RMSE e o erro absoluto médio MAE reforçam essa avaliação: em média, as previsões do modelo desviam menos de 4 MW em relação aos valores reais de PE, o que representa um erro percentual bastante reduzido frente à escala de produção típica da usina. A diferença entre RMSE e MAE — relativamente pequena — sugere ainda a ausência de erros extremos sistemáticos, indicando que o modelo não apresenta falhas graves de previsão em nenhuma região específica dos dados.

4. CONCLUSÃO

Os resultados obtidos indicam que o modelo de regressão linear múltipla apresentou um desempenho bastante satisfatório na previsão da variável dependente. O coeficiente de determinação R^2 demostra que o modelo explica bem a variação de dados, que os mesmos estão próximos da linha de regressão, com valor de 93% da variabilidade da produção de energia é explicada pelas variáveis independentes evidenciando um alto poder explicativo do modelo.

Além disso, as métricas de erros presentes na **tabela 3**, tem valores baixos, o que pode indicar uma diferença baixa entre os valores previstos e os reais o que dá força a capacidade do modelo.

Além foi constatado influências fortes de duas variáveis, AT e V, sobre a produção de energia, que as mesmas quando maiores acabam por fazer redução da produção de energia pela usina, ou seja seu desempenho. Também foi identificado correlação entre as variáveis que que causam redução, uma forte correlação, que pode ser indício de multicolinearidade o que poderia afetar a interpretação individual dos coeficientes, mas não comprometendo a capacidade do modelo de predizer.

Dessa forma, conclui-se que o modelo de regressão linear múltipla é adequado para o problema proposto, apresentando alta precisão, boa capacidade de generalização e desempenho consistente na previsão da produção de energia.

ANEXO I

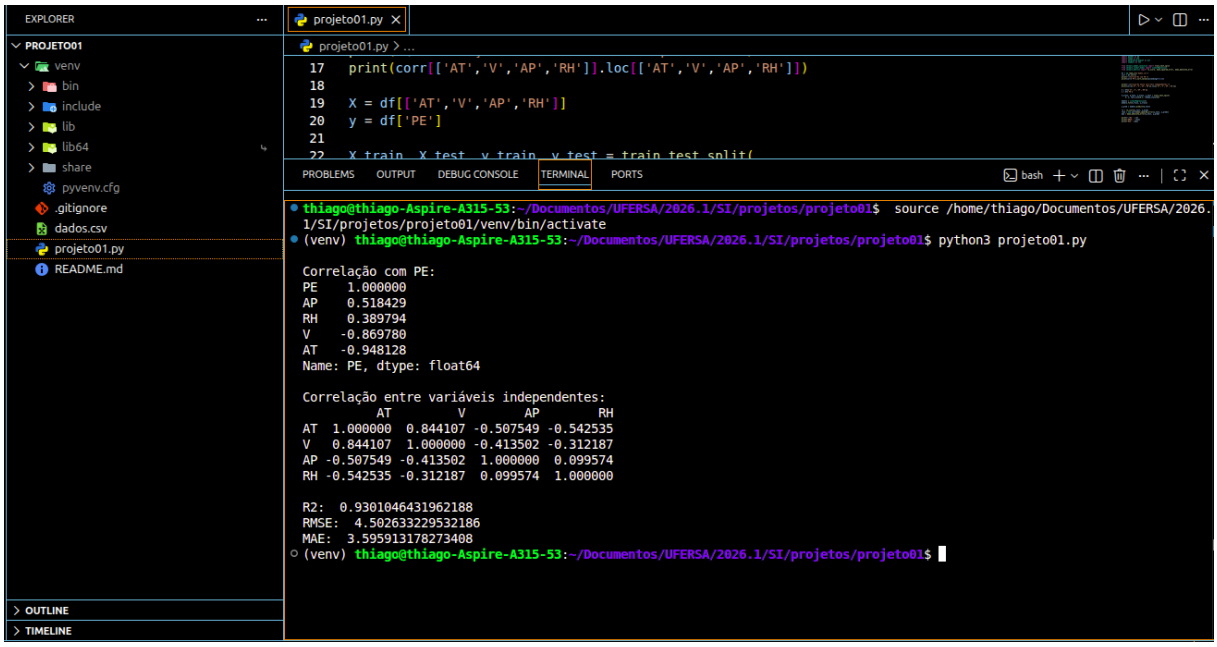
EXPLORER
projeto01.py
PROJETO01
venv
bin
include
lib
lib64
share
pyvenv.cfg
.gitignore
dados.csv
projeto01.py
README.md
OUTLINE
TIMELINE
projeto01.py > ...
17 print(corr[['AT','V','AP','RH']].loc[['AT','V','AP','RH']])
18
19 X = df[['AT','V','AP','RH']]
20 y = df['PE']
21
PROBLEMS
OUTPUT
DEBUG CONSOLE
TERMINAL
PORTS
bash
thiago@thiago-Aspire-A315-53:~/Documentos/UFERSA/2026.1/SI/projetos/projeto01$ source /home/thiago/Documentos/UFERSA/2026.1/SI/projetos/projeto01/venv/bin/activate
(venv) thiago@thiago-Aspire-A315-53:~/Documentos/UFERSA/2026.1/SI/projetos/projeto01$ python3 projeto01.py
Correlação com PE:
PE 1.000000
AP 0.518429
RH 0.389794
V -0.869780
AT -0.948128
Name: PE, dtype: float64
Correlação entre variáveis independentes:
AT V AP RH
AT 1.000000 0.844107 -0.507549 -0.542535
V 0.844107 1.000000 -0.413502 -0.312187
AP -0.507549 -0.413502 1.000000 0.099574
RH -0.542535 -0.312187 0.099574 1.000000
R2: 0.9301046431962188
RMSE: 4.502633229532186
MAE: 3.595913178273408
(venv) thiago@thiago-Aspire-A315-53:~/Documentos/UFERSA/2026.1/SI/projetos/projeto01$